



Школа информатики, физики и
технологий

Прикладной анализ данных и
искусственный интеллект


Санкт-Петербург 2026

Веб-сервис кластеризации медицинских документов

Соколовский Степан Павлович (3 курс, ПАДИИ)
Научный руководитель: преподаватель Доронькин
Максим Вячеславович

Зачем кластеризация в медицине?

- Структурирование медицинских отчетов и документации (актуально при их сегодняшнем объеме)
- Выявление скрытых групп в наборе данных, имеющих общие смысловые черты (например, обнаружение подтипа болезни, требующей особое лечение)
- Переиспользование особенностей эмбеддингов кластера (например, моделями классификации)





Цель и задачи


Цель — разработать веб-сервис для проведения экспериментов по кластеризации медицинских документов

Задачи:

- Описать архитектуру сервиса и обработку запросов в виде (схемы + openapi)
- Разработать прототип сервиса
- Реализовать выполнение задач кластеризации с переданными параметрами и возврат результата
- Реализовать хранение данных и управление кэшем эмбедингов
- Разработать графический интерфейс сервиса
- Реализовать загрузку пользовательских датасетов с предобработкой
- Добавить визуализацию результатов и описание с помощью тематического моделирования




Демонстрация работы (авторизация, запуск задач)






Архитектура сервиса (аутентификация)






Архитектура сервиса (загрузка датасета)






Архитектура сервиса (регистрация задачи)






Архитектура сервиса (выполнение задачи)





Архитектура сервиса (получение результатов)



Модифицируемость системы

- **Предобработка датасета**

- Удаление стоп-слов, характерных для мед. документов (★)
- Лемматизация

- **Векторизация**

```
def tfidf_vectorize(data, vectorize_params):
    vectorizer = TfidfVectorizer(
        **vectorize_params
    )
    X_tfidf = vectorizer.fit_transform(data.text)
    return pd.DataFrame(
        X_tfidf.toarray(),
        columns=vectorizer.get_feature_names_out(),
    )
vectorizers = {"tfidf": tfidf_vectorize, ...}
```


- **Кластеризация**

```
def cluster_kmeans(data, cluster_params):
    kmeans_model = KMeans(
        **cluster_params
    )
    clusters = kmeans_model.fit_predict(data)
    clusters = pd.DataFrame({"cluster": clusters})
    return clusters

clusterizers = {"kmeans": cluster_kmeans, ...}
```


Интерпретация кластеров с помощью тематического моделирования

- После кластеризации для каждого кластера выполняется моделирование тем, которые берутся как его описание
- Такой подход позволяет выявить отличительные черты кластеров и понять, есть ли раздробленность внутри полученных кластеров
- Облако слов не дает такой возможности, показывая слова, которые часты лишь из-за их универсальности





Демонстрация работы (просмотр результатов, служебные страницы)





Спасибо за внимание!

Контакты:
spsokolovskii@edu.hse.ru